



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Matemáticas e informática

Trabajo Fin de Grado

**Predicción de Desplazamientos de Aves
mediante Modelos Probabilísticos y
Machine Learning: Un Enfoque Híbrido**

Autor: Juan Llorens Martínez
Tutor(a): Adriana Toni Delgado

Madrid, Junio 2026

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado
Grado en Matemáticas e informática

Título: Predicción de Desplazamientos de Aves mediante Modelos Probabilísticos y Machine Learning: Un Enfoque Híbrido

Junio 2026

Autor: Juan Llorens Martínez

Tutor: Adriana Toni Delgado

[DEPARTAMENTO, ej. Departamento de Lenguajes y Sistemas Informáticos e Ingeniería de Software]
Escuela Técnica Superior de Ingenieros Informáticos
Universidad Politécnica de Madrid

Resumen

Este Trabajo Fin de Grado presenta un enfoque híbrido para la predicción de desplazamientos diarios de aves a partir de datos de geolocalización. El objetivo principal es desarrollar un sistema capaz de estimar la posición futura de un ave utilizando información histórica de su movimiento, combinando técnicas probabilísticas y de aprendizaje automático.

En primer lugar, se lleva a cabo una fase de preparación y limpieza de datos, en la que se filtran registros erróneos y se construyen secuencias temporales coherentes a partir de datos obtenidos mediante sistemas de seguimiento (Argos/GPS). A partir de estos datos, se calcula el desplazamiento diario del ave y se discretiza el espacio geográfico en celdas para facilitar el modelado.

A continuación, se emplean cadenas de Markov para modelar el comportamiento espacial del ave mediante matrices de transición que representan la probabilidad de desplazamiento entre distintas zonas, teniendo en cuenta factores como la estacionalidad. Posteriormente, se utilizan Modelos Ocultos de Markov (HMM) para inferir estados de comportamiento no observables directamente, como reposo o migración activa, a partir de variables como la distancia recorrida y los cambios de dirección.

En una fase posterior, se aplican algoritmos de Machine Learning, incluyendo Random Forest, XGBoost y LightGBM, con el objetivo de predecir el vector de desplazamiento diario del ave en función de variables temporales, espaciales y del comportamiento detectado.

Finalmente, los resultados obtenidos se evalúan mediante métricas de error y se representan sobre mapas interactivos, permitiendo comparar visualmente las trayectorias reales con las predichas. Este trabajo pone de manifiesto el potencial de combinar modelos probabilísticos y técnicas de aprendizaje automático para el análisis y predicción del comportamiento animal.

Abstract

This Final Degree Project presents a hybrid approach for predicting daily bird movements using geolocation data. The main objective is to develop a system capable of estimating the future position of a bird based on its historical movement, combining probabilistic models and machine learning techniques.

First, a data preparation and cleaning phase is carried out, where erroneous records are filtered and consistent temporal sequences are constructed from tracking data (Argos/GPS). From these data, daily displacement is computed and the geographical space is discretized into grid cells to facilitate modeling.

Next, Markov chains are used to model the spatial behavior of the bird by constructing transition matrices that represent the probability of movement between different areas, taking into account factors such as seasonality. Then, Hidden Markov Models (HMM) are applied to infer latent behavioral states, such as resting or active migration, based on features like traveled distance and changes in direction.

In a later stage, machine learning algorithms, including Random Forest, XGBoost and LightGBM, are trained to predict the daily displacement vector of the bird using temporal, spatial and behavioral features.

Finally, the results are evaluated using error metrics and visualized on interactive maps, allowing a direct comparison between real and predicted trajectories. This work highlights the potential of combining probabilistic models and machine learning techniques for the analysis and prediction of animal movement.

Tabla de contenidos

1. Introducción	1
1.1. Motivación	1
1.2. Definición del problema	1
1.3. Objetivos del trabajo	2
1.4. Estructura de la memoria	2
2. Estado del Arte y Marco Teórico	3
2.1. Análisis de movimientos animales	3
2.2. Modelos de Markov	3
2.3. Modelos Ocultos de Markov (HMM)	4
2.4. Algoritmos de Machine Learning	4
2.4.1. Random Forest	5
2.4.2. XGBoost y LightGBM	5
2.5. Tecnologías utilizadas	5
3. Metodología y Preparación de Datos	7
3.1. Origen y Descripción del Dataset	7
3.1.1. Estructura y Variables del Dataset	7
3.1.2. Variables de Identificación y Contexto	7
3.1.3. Variables Espacio-Temporales	7
3.1.4. Variables de Calidad y Control	8
3.1.5. Variables Ambientales	8
3.1.6. Selección y Transformación de Variables	8
3.2. Limpieza y Procesamiento de Datos	9
3.2.1. Análisis de la Distribución Temporal	9
3.2.2. Filtrado y Submuestreo Diario	9
3.2.3. Segmentación y Consistencia de Trayectorias	10
3.2.4. Resumen del Proceso de Filtrado	12
3.3. Feature Engineering	12
3.3.1. Cálculo de Métricas Cinemáticas y Geodésicas	12
3.3.2. Detección de Estados mediante HMM (Stacking de Características)	12
3.3.3. Discretización Espacial y Variable Objetivo	13
3.3.4. Definición del Conjunto de Predictores (Features)	13
4. Implementación del Sistema Híbrido	15

TABLA DE CONTENIDOS

4.1. Módulo Estadístico: Modelado mediante Cadenas de Markov	15
4.1.1. Discretización del Espacio (Grid System)	15
4.1.2. Generación de Transiciones y Estacionalidad	16
4.1.3. Cálculo de Probabilidades de Transición	16
4.2. Detección de comportamiento con HMM	17
4.2.1. Configuración del Modelo y Variables de Emisión	17
4.2.2. Entrenamiento e Inferencia de Estados	18
4.2.3. Integración en el Flujo Predictivo	18
4.3. Modelado con Machine Learning	18
4.3.1. Configuración de los modelos	18
4.3.2. Entrenamiento y ajuste de hiperparámetros	19
5. Visualización y Resultados	21
5.1. Visualización en mapas	21
5.2. Evaluación del modelo	21
5.3. Comparativa de algoritmos	21
6. Análisis de impacto	23
7. Conclusiones y trabajo futuro	25
Bibliografía	27
Anexos	31
A. Primer anexo	31
A.1. Feature Engineering	31
A.1.1. Cálculo de Variables Cinemáticas	31
A.1.2. Codificación Cíclica de la Estacionalidad	32
A.1.3. Inercia y Variables de Retardo (Lags)	32
A.1.4. Discretización Espacial para Cadenas de Markov	32
A.1.5. Variables de Contexto de Comportamiento	32
B. Implementación del Sistema Híbrido	33

Capítulo 1

Introducción

1.1. Motivación

El estudio del desplazamiento de aves mediante datos de localización permite analizar patrones migratorios, zonas de descanso y comportamientos espaciales de gran interés ecológico. En los últimos años, la disponibilidad de datos de seguimiento animal ha aumentado de forma considerable gracias al uso de dispositivos de geolocalización, lo que ha favorecido la aplicación de técnicas estadísticas y de inteligencia artificial al análisis del movimiento.

En el caso de las aves migratorias, predecir la posición futura de un individuo constituye un problema de especial interés, tanto desde el punto de vista biológico como tecnológico. La posibilidad de anticipar trayectorias puede contribuir a una mejor comprensión de sus rutas migratorias, de sus pautas de comportamiento y de los factores que condicionan sus desplazamientos.

1.2. Definición del problema

Este Trabajo Fin de Grado aborda el problema de la predicción de la posición diaria de aves a partir de datos históricos de localización. En concreto, se plantea un enfoque híbrido que combina modelos probabilísticos y técnicas de aprendizaje automático para estimar el desplazamiento futuro a partir de la trayectoria previa del animal.

El problema presenta varias dificultades. Por un lado, los datos de seguimiento pueden contener errores, observaciones irregulares y valores atípicos. Por otro, el movimiento de un ave no responde a una dinámica completamente determinista, sino que depende de patrones espaciales, temporales y comportamentales que deben ser modelados adecuadamente.

1.3. Objetivos del trabajo

El objetivo general de este trabajo es desarrollar un sistema capaz de predecir el desplazamiento diario de aves a partir de datos históricos de localización, combinando distintas técnicas de modelado.

De este objetivo general se derivan los siguientes objetivos específicos:

- Preparar y limpiar el conjunto de datos de seguimiento, eliminando errores y construyendo secuencias temporales coherentes.
- Modelar el movimiento espacial mediante cadenas de Markov, construyendo tablas de probabilidad de transición entre celdas del plano.
- Inferir estados de comportamiento no observables directamente mediante Modelos Ocultos de Markov.
- Aplicar algoritmos de Machine Learning para predecir el desplazamiento diario del ave.
- Evaluar los resultados obtenidos y representarlos sobre mapas para facilitar su interpretación.

1.4. Estructura de la memoria

La memoria se organiza en varios capítulos. En primer lugar, se presenta esta introducción, donde se expone la motivación del trabajo, el problema abordado, los objetivos perseguidos y la estructura general del documento.

A continuación, se desarrolla el estado del arte y marco teórico, seguido de la descripción de la metodología y de la fase de preparación de datos. Posteriormente, se expone la implementación del sistema híbrido propuesto y se presentan los resultados obtenidos junto con su visualización y evaluación.

Finalmente, se incluye un análisis de impacto del trabajo realizado y un último capítulo dedicado a las conclusiones, limitaciones y posibles líneas de trabajo futuro.

Capítulo 2

Estado del Arte y Marco Teórico

2.1. Análisis de movimientos animales

El estudio de los movimientos animales constituye una línea de investigación de gran relevancia dentro de la ecología del movimiento, ya que permite comprender cómo los individuos se desplazan en el espacio y en el tiempo, cómo utilizan el territorio y qué patrones siguen durante procesos como la migración, la alimentación o el descanso.

En el caso de las aves migratorias, el análisis del movimiento resulta especialmente interesante, debido a la gran variabilidad espacial de sus trayectorias y a la influencia de factores biológicos y ambientales sobre su comportamiento. La disponibilidad de datos de localización obtenidos mediante dispositivos de seguimiento ha permitido abordar este problema desde una perspectiva cuantitativa, apoyándose en técnicas estadísticas y computacionales.

Uno de los principales objetivos en este ámbito es no solo describir trayectorias pasadas, sino también modelar y predecir posiciones futuras. Para ello, es necesario transformar los datos brutos de localización en información útil, extrayendo variables como distancia recorrida, velocidad, dirección o cambios de rumbo, que permitan caracterizar el comportamiento espacial del animal.

2.2. Modelos de Markov

Las cadenas de Markov constituyen una herramienta probabilística ampliamente utilizada para modelar sistemas dinámicos en los que el estado futuro depende, de manera simplificada, del estado actual. En su versión de primer orden, una cadena de Markov asume que la probabilidad de transición a un nuevo estado depende únicamente del estado presente, sin necesidad de considerar toda la historia previa.

Aplicadas al problema de la predicción espacial, las cadenas de Markov permiten representar el movimiento de un ave entre distintas zonas del espacio discretizado. Para ello, el área geográfica de estudio se divide en celdas, de forma que

cada observación diaria puede asociarse a una celda concreta. A partir de la sucesión temporal de celdas visitadas, es posible construir matrices de transición que recogen la probabilidad de pasar de una celda a otra.

Este enfoque resulta útil para capturar tendencias generales de desplazamiento y patrones recurrentes de movimiento. Además, permite incorporar información contextual, como la estación del año, construyendo matrices de transición específicas para distintos periodos temporales y adaptando así el modelo al comportamiento estacional de las aves.

2.3. Modelos Ocultos de Markov (HMM)

Los Modelos Ocultos de Markov amplían la idea de las cadenas de Markov incorporando la existencia de estados internos no observables directamente. En este tipo de modelos, se asume que el sistema evoluciona entre distintos estados ocultos, mientras que las observaciones disponibles son manifestaciones indirectas de dichos estados.

En el contexto del movimiento animal, esta formulación resulta especialmente adecuada para representar comportamientos que no pueden medirse de manera explícita, como el reposo, la búsqueda de alimento o la migración activa. Aunque estos estados no se observan directamente en los datos de localización, pueden inferirse a partir de variables derivadas del movimiento, como la distancia recorrida por día o los cambios de dirección.

El uso de HMM permite, por tanto, identificar patrones de comportamiento subyacentes en la trayectoria del ave, lo que aporta una capa adicional de interpretación al análisis. Además, la información inferida sobre los estados ocultos puede utilizarse posteriormente como entrada para modelos predictivos más complejos.

2.4. Algoritmos de Machine Learning

El aprendizaje automático supervisado ofrece una vía complementaria para la predicción de desplazamientos, al permitir modelar relaciones complejas entre un conjunto de variables de entrada y una variable objetivo. A diferencia de los modelos probabilísticos clásicos, los algoritmos de Machine Learning pueden capturar dependencias no lineales y aprovechar simultáneamente múltiples características del problema.

En este trabajo, el objetivo del modelado supervisado es predecir el desplazamiento diario del ave a partir de variables temporales, espaciales y de comportamiento. Entre estas variables pueden incluirse la fecha, la posición previa, la distancia recorrida en observaciones anteriores, la estación del año o el estado inferido mediante HMM.

Dentro de los algoritmos considerados, se han seleccionado modelos basados en árboles de decisión y técnicas de boosting, por tratarse de métodos robustos, versátiles y ampliamente utilizados en problemas de predicción tabular.

2.4.1. Random Forest

Random Forest es un algoritmo de aprendizaje supervisado basado en la combinación de múltiples árboles de decisión. Cada árbol se entrena sobre una muestra aleatoria de los datos y utilizando subconjuntos aleatorios de variables, lo que reduce la varianza del modelo y mejora su capacidad de generalización.

Entre sus principales ventajas destacan su robustez frente al ruido, su capacidad para manejar relaciones no lineales y su buen rendimiento sin necesidad de una gran cantidad de ajuste manual. Además, permite estimar la importancia relativa de las variables, lo que puede resultar útil para interpretar qué factores influyen más en la predicción del desplazamiento.

2.4.2. XGBoost y LightGBM

XGBoost y LightGBM son algoritmos de boosting basados en árboles de decisión. Ambos construyen modelos aditivos en los que cada nuevo árbol trata de corregir los errores cometidos por los anteriores, lo que permite obtener predictores muy potentes.

XGBoost destaca por su precisión y por incorporar técnicas avanzadas de regularización que ayudan a evitar el sobreajuste. Por su parte, LightGBM ha sido diseñado para mejorar la eficiencia computacional, especialmente en conjuntos de datos grandes, manteniendo un alto rendimiento predictivo.

La comparación entre ambos métodos y Random Forest permite evaluar qué tipo de modelo se adapta mejor a las características del problema planteado.

2.5. Tecnologías utilizadas

La implementación del trabajo se apoya en el lenguaje de programación Python, debido a su amplia adopción en el ámbito del análisis de datos y el aprendizaje automático. Para la manipulación y transformación de datos tabulares se emplea la biblioteca Pandas, mientras que Numpy se utiliza para operaciones numéricas y tratamiento eficiente de arrays.

En la fase de modelado se recurre a bibliotecas especializadas para la construcción de modelos probabilísticos y algoritmos de Machine Learning. Asimismo, para la visualización de resultados espaciales se emplean herramientas orientadas a la representación cartográfica e interactiva, como Folium o Plotly, que permiten comparar visualmente trayectorias reales y predichas.

Capítulo 3

Metodología y Preparación de Datos

En este capítulo se describe el proceso técnico seguido para transformar los datos brutos de geolocalización en un conjunto de datos estructurado y apto para el entrenamiento de los modelos propuestos.

3.1. Origen y Descripción del Dataset

El conjunto de datos utilizado en este Trabajo Fin de Grado ha sido proporcionado por la tutora del proyecto, Adriana Toni Delgado. Los datos proceden de campañas de monitorización biológica de ejemplares de gaviota mediante dispositivos GPS.

3.1.1. Estructura y Variables del Dataset

3.1.2. Variables de Identificación y Contexto

- **event-id:** Identificador único asignado a cada registro o evento de localización individual dentro de la base de datos.
- **study-name:** Nombre del proyecto de investigación bajo el cual se recolectaron los datos.
- **individual-taxon-canonical-name:** Nombre científico de la especie monitorizada. En este caso, *Larus Fuscus*.
- **tag-local-identifier:** Código identificador del dispositivo físico (etiqueta o sensor) que porta el animal.
- **individual-local-identifier:** Código identificador del individuo concreto.

3.1.3. Variables Espacio-Temporales

- **timestamp:** Marca temporal que indica la fecha y hora exacta en la que se registró la posición. Las horas se registran en horarios en punto.

- **location-long**: Longitud geográfica expresada en coordenadas decimales.
- **location-lat**: Latitud geográfica expresada en coordenadas decimales.

3.1.4. Variables de Calidad y Control

- **visible / visible.1**: Indicadores que determinan si el registro es válido para su visualización o procesamiento.
- **manually-marked-outlier**: Variable que identifica registros considerados erróneos por inspección manual, como saltos de localización no realistas.
- **sensor-type**: Tipo de tecnología empleada para la captura de datos (en nuestro caso, siempre GPS).

3.1.5. Variables Ambientales

Estas variables provienen de modelos climáticos y geográficos externos y se asocian a la localización del individuo en cada instante temporal:

- **ECMWF Interim Full Daily Invariant Low Vegetation Cover**: Proporción de cobertura de vegetación baja en la zona geográfica, según el modelo ECMWF.
- **ECMWF Interim Full Daily Invariant High Vegetation Cover**: Proporción de cobertura de vegetación alta (bosques, árboles) en la zona geográfica.
- **NCEP NARR SFC Vegetation at Surface**: Información sobre la vegetación superficial obtenida del modelo de reanálisis NCEP NARR.

3.1.6. Selección y Transformación de Variables

Con el fin de optimizar el procesamiento de los datos y mejorar la legibilidad del código de implementación, se ha procedido a seleccionar un subconjunto de variables y renombrarlas según se muestra en el Cuadro 3.1.

Variable Original	Nombre Nuevo	Utilidad
timestamp	time	Análisis temporal y secuencias.
location-long	lon	Coordenada de longitud.
location-lat	lat	Coordenada de latitud.
individual-local-id	animal_id	Identificación de trayectoria única.
ECMWF... Low Veg	veg_low	Contexto ambiental (vegetación baja).
ECMWF... High Veg	veg_high	Contexto ambiental (vegetación alta).

Cuadro 3.1: Mapeo de variables seleccionadas para el modelo híbrido.

El resto de variables (como `event-id` o `study-name`) han sido descartadas por considerarse metadatos administrativos o información redundante que no aporta valor predictivo al cálculo de los vectores de desplazamiento de las aves.

3.2. Limpieza y Procesamiento de Datos

El objetivo de esta fase es transformar un conjunto de datos masivo y heterogéneo (+80.000 registros) en una serie temporal uniforme que permita el entrenamiento de modelos probabilísticos. El proceso se ha estructurado en tres etapas: análisis de densidad, submuestreo diario y segmentación de trayectorias.

3.2.1. Análisis de la Distribución Temporal

Dada la naturaleza de los dispositivos GPS, la frecuencia de muestreo no es constante. Para identificar los momentos de mayor disponibilidad de datos, se realizó un análisis de la distribución de registros por hora del día.

Como se observa en la Figura 3.2, existen picos de actividad muy pronunciados (a las 05:00, 08:00, 14:00 y 20:00 horas). Tras un análisis de ventanas de tres horas (pico y adyacentes), se determinó que la franja central del día presentaba la mayor estabilidad para establecer una "posición diariarepresentativa del ave.




Figura 3.1: Distribución de registros originales por hora del día.

3.2.2. Filtrado y Submuestreo Diario

Para los modelos de Markov y Machine Learning propuestos, es necesario disponer de un único punto geográfico por día. Se ha optado por un criterio de *proximidad al mediodía solar* (14:00h) para estandarizar la muestra. El algoritmo de selección sigue la siguiente lógica:

1. Se calcula la diferencia absoluta en segundos entre cada registro y la hora objetivo (14:00:00).
2. Por cada animal e identificador de día, se selecciona únicamente el registro con la diferencia mínima (*closest-to-target*). Se observa que hay 23585 registros únicos por día correspondientes a cada animal.
3. Se aplica un filtro de tolerancia de ± 1 hora, descartando registros cuya captura se alejara excesivamente del bloque central (fuera del rango 13:00h-

Capítulo 3. Metodología y Preparación de Datos

15:00h). Tras este último paso se pierden un 5,13 % de los datos, quedando 22375 registros totales.

Este proceso de limpieza reduce el dataset de forma drástica pero necesaria, garantizando que la inercia del movimiento calculada posteriormente sea coherente y comparable entre días.




Figura 3.2: Distribución de registros tras filtrar por cercanía a las 14:00


3.2.3. Segmentación y Consistencia de Trayectorias

La potencia predictiva de una Cadena de Markov o un HMM depende de la continuidad de los datos. Un salto de varios días en el seguimiento de un ave rompería la lógica del vector de desplazamiento. Por ello, se ha implementado un algoritmo de segmentación:


- **Detección de saltos:** Se calcula la diferencia de días entre registros consecutivos de un mismo individuo. Si la diferencia es > 1 día, se considera que la secuencia se ha roto.
- **Generación de ID de Trayectoria:** Se asigna un identificador único (`trayectoria_id`) a cada bloque de días consecutivos.
- **Filtro de longitud mínima:** Se han descartado todas aquellas trayectorias con una duración inferior a **4 días**.

Este último filtro es fundamental: una secuencia de 2 o 3 días no permite capturar patrones de comportamiento o cambios de estado significativos. Tras este proceso, se pierde una cantidad mínima de registros, 334 que supondrían un 1,49% de los 22375 registros anteriores, y se obtendrían 480 segmentos con una media de 46 días seguidos por segmento, lo cual es una longitud media de días suficiente para el entrenamiento robusto de los modelos de *Machine Learning*.

3.2. Limpieza y Procesamiento de Datos



(a) Identificación de saltos temporales (días entre registros).



(b) División del historial del ave en 9 segmentos continuos.

Figura 3.3: Proceso de segmentación para el ave 91739A basado en la continuidad temporal.

3.2.4. Resumen del Proceso de Filtrado

El impacto del preprocesamiento en el volumen de datos se resume en la Tabla 3.2.

Estado del Dataset	Nº Registros
Dataset Original	89867
Filtrado por cercanía a 14:00h	23585
Eliminación de horas atípicas ($\pm 1h$)	22375
Dataset Final (Secuencias ≥ 4 días)	22041

Cuadro 3.2: Evolución del número de registros durante el proceso de limpieza.

3.3. Feature Engineering

Una vez obtenidas las trayectorias limpias y continuas, se procedió a la fase de ingeniería de características. Este proceso es fundamental para transformar registros estáticos de posición en indicadores dinámicos que permitan a los modelos capturar la "memoria" del movimiento, la intención de desplazamiento y el comportamiento biológico subyacente del ave [cite: 9, 34]. El objetivo técnico es convertir las coordenadas brutas en un vector de características (feature vector) que alimente el enfoque híbrido propuesto [cite: 9].

3.3.1. Cálculo de Métricas Cinemáticas y Geodésicas

Para describir el movimiento entre dos instantes de tiempo t y $t+1$, se implementaron funciones personalizadas basadas en trigonometría esférica que operan sobre las coordenadas de latitud y longitud:

- **Distancia de salto (Step Length):** Se calcula la distancia geodésica mediante la fórmula de Haversine para considerar la esfericidad terrestre (radio medio $R = 6371$ km). Esta métrica es la principal entrada para que el modelo HMM discrimine estados de baja o alta movilidad.
- **Rumbo (Bearing):** Se calcula el ángulo de dirección inicial desde el punto P_t al punto P_{t+1} respecto al norte geográfico, normalizado en el rango $[0, 360^\circ)$.
- **Ángulo de giro (Turning Angle):** Se obtiene mediante la diferencia de rumbos consecutivos: $\Delta\theta = \theta_t - \theta_{t-1}$. Para asegurar la consistencia física, los ángulos se normalizaron en el intervalo $(-\pi, \pi]$ utilizando la función $\arctan2$ sobre los componentes seno y coseno de la diferencia. Un valor cercano a 0 indica vuelo rectilíneo, mientras que valores cercanos a $\pm\pi$ indican cambios de sentido o movimientos erráticos.

3.3.2. Detección de Estados mediante HMM (Stacking de Características)

Siguiendo el objetivo O3 del proyecto [cite: 9], se entrenó un Modelo Oculto de Markov (HMM) con distribución Gaussiana y matriz de covarianza diagonal. El

estado predicho por este modelo (`estado_hmm`), que clasifica cada punto en categorías de comportamiento como reposo.^o "vuelo/migración", se reintroduce en el dataset como una variable predictora para la etapa final de Machine Learning.

3.3.3. Discretización Espacial y Variable Objetivo

Para convertir la predicción de coordenadas en un problema de clasificación multiclase apto para algoritmos como XGBoost o LightGBM, se realizó una discretización del espacio:

1. **Sistema de Rejilla (Grid System):** Se definieron celdas con una resolución de $0,5^\circ$. Cada coordenada continua (lat, lon) se mapea a índices discretos ($grid_x, grid_y$).
2. **Identificador de Celda (`cell_id`):** Se generó una etiqueta única para cada cuadrado de la rejilla concatenando sus coordenadas discretas.
3. **Definición del Target:** La variable objetivo (`target_cell`) se genera mediante un desplazamiento temporal (*shift*), asignando a cada registro en t la celda ocupada por el animal en $t + 1$.

3.3.4. Definición del Conjunto de Predictores (Features)

La arquitectura del sistema híbrido se basa en una transferencia de información jerárquica. Es fundamental distinguir qué variables actúan como señales para el modelo probabilístico (HMM) y cuáles conforman el vector de entrada final para el entrenamiento de los clasificadores de Machine Learning.

Variables de entrada para el modelo HMM

El modelo HMM utiliza 4 variables de emisión para inferir el estado latente del ave:

- **step_length:** Magnitud del desplazamiento.
- **turning_angle:** Rectitud de la trayectoria.
- **veg_low** y **veg_high:** Contexto de cobertura vegetal ambiental.

Variables de entrada para los algoritmos de Machine Learning

El dataset final para Random Forest, XGBoost y LightGBM integra **9 predictores clave** que ofrecen una visión multidimensional (espacial, cinemática, biológica y temporal):

1. **grid_x:** Posición en el eje X de la rejilla (longitud discretizada).
2. **grid_y:** Posición en el eje Y de la rejilla (latitud discretizada).
3. **step_length:** Distancia recorrida en el último paso.
4. **turning_angle:** Ángulo de giro entre los últimos dos vectores.

Capítulo 3. Metodología y Preparación de Datos

5. **bearing**: Rumbo absoluto del movimiento.
6. **estado_hmm**: Estado de comportamiento detectado (salida del HMM).
7. **veg_low**: Cobertura de vegetación baja.
8. **veg_high**: Cobertura de vegetación alta.
9. **mes_num**: Mes del registro (extraído de la variable `date`) para capturar la estacionalidad migratoria.

El Cuadro 3.3 resume la distribución de estas variables según su función en el flujo de trabajo.

Variable	Tipo de Dato	Input HMM	Input ML
grid_x / grid_y	Espacial		✓
step_length	Cinemática	✓	✓
turning_angle	Cinemática	✓	✓
bearing	Cinemática		✓
veg_low / veg_high	Ambiental	✓	✓
estado_hmm	Comportamiento	(Salida)	✓
mes_num	Temporal		✓

Cuadro 3.3: Resumen de predictores y su participación en las etapas del modelo híbrido.

Capítulo 4

Implementación del Sistema Híbrido

4.1. Módulo Estadístico: Modelado mediante Cadenas de Markov

El núcleo del sistema de predicción se basa en un modelo estocástico de Cadenas de Markov de primer orden. Este enfoque asume la hipótesis de Markov, la cual establece que la probabilidad de que el sistema alcance un estado futuro depende exclusivamente del estado actual, ignorando el historial de estados previos.

4.1.1. Discretización del Espacio (Grid System)

Para transformar las coordenadas geográficas continuas en estados discretos tratables por el modelo, se ha implementado un sistema de rejilla o *grid*. Se ha definido una resolución de $0,5^\circ$, lo que permite agrupar las posiciones de las aves en celdas finitas. Cada celda se identifica mediante un identificador único (*cell_id*) derivado de sus índices espaciales.

Listing 4.1: Discretización espacial y generación de estados.

```
# Configuración del Grid (Resolución 0.5)
res = 0.5
lon_min, lat_min = df_final['lon'].min(), df_final['lat'].min()

# Calcular coordenadas e ID de celda
df_final['grid_x'] = ((df_final['lon'] - lon_min) / res).astype(int)
df_final['grid_y'] = ((df_final['lat'] - lat_min) / res).astype(int)
df_final['cell_id'] = df_final['grid_x'].astype(str) + "_" + df_final['grid_y']
```

4.1.2. Generación de Transiciones y Estacionalidad

Una transición se define como el desplazamiento de un ave desde una celda i en el tiempo t hacia una celda j en el tiempo $t + 1$. Para capturar estas transiciones, se ha procesado el dataset agrupando por trayectoria y desplazando temporalmente los registros.

Justificación de la Separación Mensual

Dada la naturaleza migratoria de las especies analizadas, el comportamiento de desplazamiento no es constante a lo largo del año. Como se observa en la Figura 4.1, la densidad de datos varía significativamente, presentando picos de actividad en los meses de agosto (2.991 registros) y septiembre (3.063 registros), coincidiendo con periodos migratorios clave.

Por ello, se ha optado por generar ****12 matrices de transición independientes****. Esta segmentación evita que el comportamiento de los meses con mayor volumen de datos sesgue las predicciones en meses con menor actividad (como mayo, con 1.175 registros), permitiendo un modelo sensible a la estacionalidad biológica.




Figura 4.1: Distribución acumulada de los registros de posición por mes.

4.1.3. Cálculo de Probabilidades de Transición

Para cada mes m , la probabilidad de transición P_{ij} desde la celda i a la celda j se calcula mediante la frecuencia relativa:

$$P_{ij}(m) = \frac{N_{ij}(m)}{\sum_k N_{ik}(m)} \quad (4.1)$$

Donde $N_{ij}(m)$ representa el número total de saltos observados desde el estado

4.2. Detección de comportamiento con HMM

i al estado j durante el mes m . El resultado es una matriz estocástica donde la suma de las filas es igual a la unidad.

Listing 4.2: Cálculo de matrices de transición mensuales.

```
for mes in range(1, 13):
    df_mes = df_markov[df_markov['mes_num'] == mes]
    if not df_mes.empty:
        # Contar frecuencias de saltos (origen -> destino)
        matriz = df_mes.groupby(['cell_id', 'next_cell_id']).size().reset_index()

        # Normalizar para obtener probabilidades
        suma_origen = matriz.groupby('cell_id')['frecuencia'].transform('sum')
        matriz['probabilidad'] = matriz['frecuencia'] / suma_origen

    matrices_mensuales[mes] = matriz
```

4.2. Detección de comportamiento con HMM

El segundo módulo del sistema híbrido tiene como objetivo la identificación de estados de comportamiento no observables directamente (estados latentes) a partir de las secuencias de movimiento y el contexto ambiental. Para ello, se ha implementado un Modelo Oculto de Markov (HMM) utilizando la librería `hmmlearn`.

4.2.1. Configuración del Modelo y Variables de Emisión

A diferencia de los modelos de Markov simples, el HMM asume que el estado real del ave (ej. "migración." reposo") es una variable oculta que genera las observaciones visibles. En este trabajo, se ha configurado un modelo `GaussianHMM` con las siguientes especificaciones técnicas:

- **Variables de emisión (X):** Se han seleccionado cuatro predictores que combinan la cinemática y el entorno: `step_length`, `turning_angle`, `veg_low` y `veg_high`.
- **Componentes latentes:** Se han definido $n = 2$ estados biológicos para simplificar la clasificación en comportamientos de baja y alta movilidad.
- **Matriz de covarianza:** Se ha especificado un tipo de covarianza `diag` (diagonal), lo que implica que el modelo estima una varianza independiente para cada una de las variables de emisión, asumiendo que no hay correlación directa entre ellas dentro de un mismo estado.
- **Optimización:** El modelo se entrena mediante el algoritmo de Esperanza-Maximización (EM) con un límite de 2000 iteraciones para asegurar la convergencia de las probabilidades de transición y emisión.

4.2.2. Entrenamiento e Inferencia de Estados

El entrenamiento se realiza de forma no supervisada sobre la matriz de datos consolidada. Una vez ajustados los parámetros del modelo, se aplica el algoritmo de Viterbi para predecir la secuencia de estados más probable para cada trayectoria.

La salida del modelo es una variable categórica (`estado_hmm`) que clasifica cada registro en uno de los dos estados posibles:

1. **Estado de Reposo/Forrajeo:** Caracterizado por distancias de salto cortas (`step_length` bajo) y ángulos de giro elevados (`turning_angle` cercano a $\pm\pi$), lo que indica movimientos erráticos en áreas localizadas. Suele asociarse a valores específicos de cobertura vegetal.
2. **Estado de Movimiento/Migración:** Caracterizado por distancias de salto largas y ángulos de giro pequeños (cerca de 0), indicando una trayectoria rectilínea y persistente hacia un objetivo.

4.2.3. Integración en el Flujo Predictivo

La relevancia de este módulo radica en su capacidad para aportar valor semántico a los datos brutos. Como se detalló en el proceso de *feature engineering*, la etiqueta del estado actual (`estado_hmm`) se utiliza como un predictor de entrada para los algoritmos de Machine Learning. Esta arquitectura permite que el clasificador final ajuste su predicción espacial (la siguiente celda) basándose en si el ave se encuentra en una fase de desplazamiento activo o de permanencia en el lugar.

4.3. Modelado con Machine Learning

El tercer componente del sistema híbrido se basa en algoritmos de aprendizaje supervisado orientados a predecir el desplazamiento diario del ave. En esta fase se construyen modelos que reciben como entrada variables temporales, espaciales y de comportamiento, y generan como salida una estimación del movimiento futuro.

4.3.1. Configuración de los modelos

Se consideran tres algoritmos principales: Random Forest, XGBoost y LightGBM. Cada uno de ellos presenta características particulares en términos de robustez, capacidad de generalización y eficiencia computacional.

La configuración inicial de los modelos implica seleccionar las variables de entrada, definir la variable objetivo y establecer una estrategia de partición de datos en entrenamiento y prueba. Dado el carácter temporal del problema, resulta especialmente importante evitar fugas de información entre ambos conjuntos.

4.3.2. Entrenamiento y ajuste de hiperparámetros

Una vez definidos los modelos, se lleva a cabo el proceso de entrenamiento y ajuste de hiperparámetros. Este ajuste tiene como finalidad mejorar el rendimiento predictivo de cada algoritmo, controlando aspectos como la profundidad de los árboles, el número de estimadores o la tasa de aprendizaje en los métodos de boosting.

La comparación entre configuraciones se realiza atendiendo a métricas de error obtenidas sobre el conjunto de validación o prueba, con el objetivo de seleccionar la alternativa más adecuada para el problema planteado.

Capítulo 5

Visualización y Resultados

5.1. Visualización en mapas

La representación visual de las trayectorias constituye un elemento fundamental para interpretar los resultados del sistema propuesto. Por ello, se desarrolla un módulo cartográfico que permite mostrar sobre mapas las rutas reales de las aves y compararlas con las trayectorias predichas por los distintos modelos.

Este tipo de visualización facilita la identificación de patrones espaciales, errores sistemáticos de predicción y diferencias entre métodos. Además, aporta una perspectiva intuitiva que complementa el análisis cuantitativo basado en métricas numéricas.

5.2. Evaluación del modelo

La evaluación del sistema se realiza comparando las posiciones o desplazamientos predichos con los valores reales observados. Para ello se emplean métricas de error expresadas en kilómetros, adecuadas al contexto espacial del problema.

El análisis de resultados permite valorar hasta qué punto cada enfoque es capaz de capturar la dinámica del movimiento del ave y qué limitaciones presenta en función de la resolución temporal, la calidad de los datos y la variabilidad del comportamiento migratorio.

5.3. Comparativa de algoritmos

Una vez obtenidos los resultados de los distintos enfoques, se realiza una comparativa entre los modelos probabilísticos y los algoritmos de Machine Learning considerados. Esta comparación permite identificar cuáles ofrecen un mejor rendimiento predictivo y bajo qué condiciones.

Asimismo, se analiza el valor añadido del enfoque híbrido, evaluando si la combinación de cadenas de Markov, HMM y Machine Learning proporciona ventajas frente al uso aislado de cada técnica.

Capítulo 6

Análisis de impacto

En este capítulo se realizará un análisis del impacto potencial de los resultados obtenidos durante la realización del TFG, en los diferentes contextos para los que se aplique:

- Personal
- Empresarial
- Social
- Económico
- Medioambiental
- Cultural

En dicho análisis se destacarán los beneficios esperados, así como también los posibles efectos adversos.

Se recomienda analizar también el potencial impacto respecto a los Objetivos de Desarrollo Sostenible (ODS), de la Agenda 2030, que sean relevantes para el trabajo realizado (ver enlace)

Además, se harán notar aquellas decisiones tomadas a lo largo del trabajo que tienen como base la consideración del impacto.

Capítulo 7

Conclusiones y trabajo futuro

Resumen de resultados obtenidos en el TFG, conclusiones personales del estudiante sobre el trabajo realizado y potencial trabajo futuro si existiera.

Bibliografía

Anexos

Apéndice A

Primer anexo

Este capítulo (anexo) es opcional, y se escribirá de acuerdo con las indicaciones del Tutor.

A.1. Feature Engineering

Una vez obtenidas las trayectorias limpias y continuas, el siguiente paso consiste en la generación de variables derivadas que permitan a los modelos capturar la dinámica del movimiento. El objetivo es convertir registros estáticos de posición en indicadores de intención y comportamiento.

A.1.1. Cálculo de Variables Cinemáticas

Para describir el movimiento entre dos instantes de tiempo t y $t + 1$, se han calculado las siguientes métricas fundamentales:

- **Distancia de salto (Step Length):** Se calcula la distancia geodésica entre puntos consecutivos utilizando la fórmula de Haversine para considerar la esfericidad de la Tierra. Esta variable es crítica para que el modelo HMM distinga entre estados de reposo (distancias cortas) y migración (distancias largas).
- **Velocidad aparente:** Dado que el intervalo temporal está estandarizado a 24 horas, la velocidad se trata como la relación directa entre la distancia recorrida y el tiempo transcurrido, expresada en km/día.
- **Ángulo de giro (Turning Angle):** Define la desviación angular entre el vector de movimiento previo ($P_{t-1} \rightarrow P_t$) y el actual ($P_t \rightarrow P_{t+1}$). Un ángulo cercano a 0° indica una trayectoria rectilínea persistente, mientras que ángulos cercanos a 180° sugieren cambios de dirección bruscos o movimientos de búsqueda de alimento.

A.1.2. Codificación Cíclica de la Estacionalidad

Como se indica en los objetivos del trabajo, el movimiento de las aves depende fuertemente de la estación del año. Para que los modelos de *Machine Learning* (Random Forest, XGBoost) comprendan que el 31 de diciembre y el 1 de enero son fechas contiguas, se ha aplicado una transformación trigonométrica al día del año ($d \in [1, 365]$):

$$day_sin = \sin\left(\frac{2\pi \cdot d}{365}\right), \quad day_cos = \cos\left(\frac{2\pi \cdot d}{365}\right) \quad (\text{A.1})$$

Estas dos nuevas variables permiten representar la estacionalidad en un espacio bidimensional continuo, facilitando la detección de patrones migratorios anuales.

A.1.3. Inercia y Variables de Retardo (Lags)

Para modelar la inercia del movimiento mencionada en la propuesta original, se han generado variables de retardo. Esto permite que el modelo en el instante t conozca el estado del ave en el pasado inmediato:

- **Delta Lon / Delta Lat ($t - 1$):** El vector de desplazamiento realizado el día anterior.
- **Rumbo previo:** La dirección seguida en la última jornada, asumiendo que las aves suelen mantener cierta persistencia en sus rutas migratorias.

A.1.4. Discretización Espacial para Cadenas de Markov

Para el cumplimiento del objetivo O2 (predicción estadística con Markov), se ha procedido a la creación de un sistema de rejilla (*grid*). Las coordenadas continuas de latitud y longitud se mapean a identificadores de celda únicos. El tamaño de la celda se ha ajustado para equilibrar la precisión espacial con la densidad de la matriz de transición, evitando que la mayoría de las celdas tengan una probabilidad de transición nula.

A.1.5. Variables de Contexto de Comportamiento

Finalmente, se ha reservado un espacio para la integración de la salida del modelo HMM (objetivo O3). El estado detectado por el HMM (por ejemplo, "migración activa.º reposo") se reintroduce en el dataset como una variable categórica. Esta técnica de *stacking* permite que los algoritmos de *Machine Learning* ajusten el vector de desplazamiento predicho en función del estado de comportamiento identificado por el modelo probabilístico.

Apéndice B

Implementación del Sistema Híbrido